

DAMON in Production

Experiences · Gaps · Future Directions

王炼 / [lianux.mm](https://github.com/lianux-mm)

进程使命（上海）科技有限公司 · 高级内核研发工程师
“笑傲内核” 发起人 & PM

陈涛 Kunwu Chan

“笑傲内核” 发起人之一
麒麟软件 资深研发工程师

lianux.mm@gmail.com | github.com/lianux-mm

30-Second Overview

T1/T2 发现两个坑

- TLB 盲点 (T1)
- PMD 粒度放大 (T2)

FIX 修复了它们

- `min_nr_accesses=0`
- `address filter` 精确选择

SPE 推进硬件辅助

- 联合 ARM + 华为
- SPE 精确反馈机制

DAMON 极简回顾

DAMON 监控

- 采样 Accessed Bit (AF)
- 自适应区域合并/拆分
- 访问频率计数
- 年龄追踪 (age)

DAMOS 执行

- pageout 冷页
- collapse 大页 (新增)
- split 大页 (新增)
- 基于 Access Pattern 触发

T1 : TLB 盲点

问题根源

Kunpeng 920 L2 TLB :

2048 entries $\times$ 2MB = 4GB 覆盖

Working set < 4GB 时 :

CPU 访问 $\rightarrow$ TLB 命中 $\rightarrow$ 不走页表

AF 永远不会被重新设置

DAMON 看到 nr_accesses = 0

所有 DAMOS 策略都不触发 $\triangle$ 疣

修复方案

`min_nr_accesses = 0`

让 scheme 在 AF=0 时也可触发


由 address filter 做精确目标选择

影响 : 小内存工作负载下 DAMON 完全失明 · 架构无关, x86 和 ARM 均受影响

T2 : PMD 粒度放大

实际情况


2MB THP (512 个子页)



~5% 子页实际被访问 (绿色)

DAMON 看到

整个 2MB 标记为 hot !



PMD
AF


PMD 级 AF : 1 个 bit 覆盖 2MB

根本原因 : `ptep_test_and_clear_young()` 不刷 TLB · x86 和 ARM64 均受影响

ARM SPE 生产数据验证

94.6%

的 2MB THP 只有
< 10% 子页被访问



数据来源：深信服 Kunpeng 920 物理机，KVM + Oracle DB，ARM SPE 采样分析

结论：大量 2MB THP 中只有极少子页热，冷热不均 → 内存浪费严重

解决方案：v2 内核补丁（5 个 Patch）

P1

target_order 字段

struct damos 新增 target_order，指定 mTHP 目标 order；sysfs 暴露

P2

damon_collapse_folio_range()

从 khugepaged 导出 mTHP collapse 能力供 DAMON 调用

P3

DAMOS_COLLAPSE handler

damos_va_collapse()：对目标区域 folio 执行 collapse

P4

DAMOS_SPLIT action（新增）

枚举新增 DAMOS_SPLIT，sysfs action 名: "split"

P5

DAMOS_SPLIT handler

damos_va_split()：对目标 folio 执行 split_folio_to_order()

v1→v2 变化 (SJ 审核)：DAMOS_SPLIT 命名统一·删除 hot_threshold（策略放用户态）

架构设计：内核机制 + 用户态策略

用户态（决策层）

perf record
(SPE)

spe_hist
热度分析

pfn_to_va
PA→VA

DAMON sysfs
address filter

↓ 稀疏 THP 的 VA 范围

内核（执行层）

DAMON 监控 → address filter 命中 → DAMON_SPLIT / DAMON_COLLAPSE → split_folio_to_order()

设计原则：内核提供机制，用户态做策略 · 与 perf/BPF 模式一致

ARM SPE vs DAMON AF : 精度对比

维度	DAMON (AF)	ARM SPE
数据来源	页表 Accessed Bit	CPU 流水线物理地址
粒度	PMD (2MB)	缓存行 (64B)
TLB 影响	有 (T1 盲点)	无 (绕过 TLB)
放大问题	有 (T2 inflate)	无 (独立计数)
架构支持	所有架构	ARMv8.2+

ARM SPE 直接从 CPU 流水线采样物理地址，完全绕开 TLB 和页表，精度高出数个数量级

测试验证 (smaps 路径)

运行时间	sz_tried	sz_applied	拆分 THP 数	结果
5s	~2 GB	32 MB	16	16/16 文
10s	~4.4 GB	42 MB	~21	全部 文
60s	~24 GB	~38 MB	~19	全部 文

验证平台

鲲鹏 arch64 VM (无 SPE , smaps 路径)

鲲鹏 Kunpeng 920 物理机 (smaps 路径验证通过 , SPE 路径调试中)

测试负载 : hot_workload 32MB · sz_tried >> sz_applied 说明 address filter 有效过滤

未来方向

短期

- 发送 v2 到 linux-mm/damon 邮件列表
- SJ review → v3 迭代
- 修复 SPE 路径 sz_tried=0 问题

中期

- 联合 ARM + 华为推动 SPE→DAMON 方案
- 探索 x86 PEBS 类似能力
- DAMON 原生子 PMD 粒度采样

长期

- DAMON 成为 Linux 内存管理的「标准传感器」
- 硬件数据源可替换 (SPE/IBS/PEBS)
- 内核机制不变，用户态策略自由组合

三个关键信息

1

两个已知局限

T1 TLB 盲点 + T2 PMD 粒度放大
架构无关，所有 THP 场景受影响

2

v2 补丁提供 mTHP 机制

内核执行 / 用户态决策 / SPE 可选加速
Damos_COLLAPSE + DAMOS_SPLIT

3

社区联合推动是关键

ARM + 华为 + 社区共建
让「用户态分析 + 内核执行」架构进入上游